ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
Khoa Khoa học và Kỹ thuật Máy tính

ĐỒ ÁN KỸ THUẬT DỮ LIỆU

Đề tài

"Phân tích các yếu tố kinh tế – xã hội ảnh hưởng đến tuổi thọ trung bình toàn cầu"

GVHD: Vũ Ngọc Tú

Sinh viên: Phạm Đình Được 2310761
Bùi Quang Huy 2311124
Võ Thanh Đạt 2310717

Thành phố Hồ Chí Minh, Tháng 9/2025

Bảng phân công nhiệm vụ & Mức độ hoàn thành

Thành viên	**MSSV**	**%Done**
Phạm Đình Được	2310761	100%
Bùi Quang Huy	2311124	100%
Võ Thanh Đạt	2310717	100%

Mục lục

1 Tổng quan **6**
1.1 Đặt vấn đề . . . 6
1.2 Mục tiêu và phạm vi đề tài . . . 6
1.2.1 Mục tiêu nghiên cứu chính . . . 6
1.2.2 Ứng dụng thực tiễn và chính sách . . . 6
1.2.3 Mục tiêu kỹ thuật . . . 7
1.3 Phương pháp tiếp cận . . . 7

2 Cơ sở lý thuyết (Theoretical background) **8**
2.1 Linear Regression . . . 8
2.1.1 Phân loại Linear Regression . . . 8
2.1.2 Best Fit Line và Hàm mất mát (Cost Function) . . . 8
2.1.3 Gradient Descent . . . 9
2.1.4 Cách tối ưu hóa trong thư viện `scikit-learn` . . . 9
2.1.5 Các giả định của Linear Regression . . . 10
2.2 SVR . . . 10
2.2.1 Các thành phần cốt lõi . . . 10
2.2.2 Mô hình Toán học . . . 10
2.2.3 Xử lý nhiễu: Biến bù (Slack Variables) . . . 11
2.2.4 Kernel Functions (Hàm nhân) . . . 11
2.3 Các chỉ số đánh giá mô hình Hồi quy (Regression Metrics) . . . 11
2.3.1 Mean Absolute Error (MAE) . . . 11
2.3.2 Root Mean Squared Error (RMSE) . . . 12
2.3.3 R-Squared (R^2 Score) . . . 12

3 Khám phá và tiền xử lý số liệu (Data Preparation and Exploration) **13**
3.1 Tổng quan dữ liệu . . . 13
3.1.1 Lựa chọn tập dữ liệu . . . 13
3.1.2 Giới thiệu tập dữ liệu . . . 13
3.2 Phân tích và khám phá dữ liệu (EDA) . . . 15
3.2.1 Mục tiêu . . . 15
3.2.2 Kiểm tra dữ liệu thiếu (Missing value) . . . 15
3.2.3 Biểu đồ tương quan . . . 15
3.3 Tiền xử lý dữ liệu . . . 16
3.3.1 Làm sạch dữ liệu . . . 16
3.3.2 Chia tập dữ liệu . . . 16
3.3.3 Feature Selection . . . 18

4 Hiện thực mô hình nghiên cứu **20**
4.1 Quy trình tiến hành . . . 20
4.2 Phân tích đa cộng tuyến VIF . . . 20
4.3 Huấn luyện và kiểm thử mô hình . . . 21
4.3.1 Huấn luyện mô hình . . . 22
4.3.2 Kiểm thử mô hình . . . 22
4.4 Kiểm định mô hình . . . 23
4.5 Residual Analysis . . . 24

4.5.1 Phân tích sai số 24
4.5.2 Các mẫu có sai số lớn 24
4.6 Tương quan giữa Residual và biến đầu vào 26

5 Trực quan hoá dữ liệu với Dashboard 27
5.1 Thiết kế Dashboard 27
5.2 Các Insight rút ra 27
5.2.1 EDA Dashboard 27
5.2.2 Dashboard mô tả mô hình được huấn luyện 29

6 Kết luận và Hướng phát triển 31
6.1 Kết luận 31
6.2 Hạn chế và Hướng phát triển 31

7 Tài liệu tham khảo (Reference) 32

8 Mã nguồn 32

Danh sách hình vẽ

1 Biểu đồ tương quan giữa các biến 16
2 Phân bố tuổi thọ trung bình tại các tập Train - Valid - Test 17
3 Phân bố vùng tại các tập Train - Valid - Test 18
4 Top 12 features có mức ảnh hưởng cao nhất (SVR) 19
5 Biểu đồ sai số của 2 mô hình 24
6 Phân bố giá trị của 2 mô hình và giá trị thực tế 24
7 Biểu đồ tương quan giữa phần dư và các biến đặc trưng 26
8 EDA Dashboard 27
9 Models Result Dashboard 29

Listings

1 Code vẽ Ma trận tương quan 15
2 devide.py - Chia tập dữ liệu 17
3 main.py - Feature Selection 18
4 Result - Top 12 correlated features with LifeExpBirth 20
5 Result - Top 12 correlated features with LifeExpBirth after remove GNI 21
6 main.py - Huấn luyện và kiểm thử mô hình (Model Training and Validation) 22
7 Result - Kết quả kiểm thử trên tập Validation 22
8 Result - Kết quả lựa chọn mô hình tối ưu 22
9 Result - main.py - Test Module 23
10 Result - Kết quả kiểm định mô hình 23
11 Các mẫu có sai số lớn nhất của Linear Regression 24
12 Các mẫu có sai số lớn nhất của SVR 25
13 Các mẫu có sai số lớn nhất của SVR 25

1 Tổng quan

1.1 Đặt vấn đề

Trong bối cảnh toàn cầu hiện nay, tuổi thọ trung bình là một chỉ số vĩ mô phản ánh rõ nét nhất về sức khỏe cộng đồng, chất lượng cuộc sống, và hiệu quả của các chính sách y tế - xã hội của một quốc gia. Thế giới đang phải đối mặt với hai xu hướng nhân khẩu học lớn: sự già hóa dân số nhanh chóng ở nhiều nước phát triển và sự gia tăng đáng kể của các bệnh không lây nhiễm (như bệnh tim mạch, tiểu đường) ngay cả ở các nước đang phát triển. Hơn nữa, những biến động toàn cầu như đại dịch COVID-19 gần đây đã cho thấy sự mong manh của tuổi thọ trung bình trước các cú sốc bên ngoài, đồng thời làm lộ rõ những bất bình đẳng sâu sắc về sức khỏe giữa các nhóm dân cư và khu vực.

Xuất phát từ tình hình cấp thiết trên, việc phân tích dữ liệu các yếu tố kinh tế - xã hội có ảnh hưởng đến tuổi thọ trung bình trở nên vô cùng cần thiết. Mục tiêu của nghiên cứu này không chỉ dừng lại ở việc mô tả xu hướng mà còn đi sâu vào khai phá mối quan hệ giữa tuổi thọ trung bình và các chỉ số kinh tế - xã hội.

Sử dụng các phương pháp phân tích dữ liệu, nghiên cứu sẽ cung cấp một cái nhìn đa chiều và định lượng về những yếu tố nào có tác động mạnh mẽ nhất và tiêu cực/tích cực nhất đến tuổi thọ trung bình. Từ đó hỗ trợ hoạch định chính sách - Các kết quả phân tích sẽ là cơ sở khoa học vững chắc để hỗ trợ chính phủ và các cơ quan chức năng trong việc ra quyết định.

Tóm lại, đề tài này đóng vai trò là cầu nối quan trọng giữa Dữ liệu thô và Chính sách y tế - xã hội hiệu quả, góp phần thiết thực vào mục tiêu nâng cao sức khỏe và chất lượng sống cho người dân.

1.2 Mục tiêu và phạm vi đề tài

1.2.1 Mục tiêu nghiên cứu chính

- Xác định yếu tố kinh tế – xã hội nào ảnh hưởng mạnh nhất đến tuổi thọ trung bình (Life Expectancy).
- Đo lường ảnh hưởng của các biến như Thu nhập quốc dân bình quân đầu người (GNI/CapAtlas), Tỷ lệ tử vong trẻ dưới 5 tuổi (MortRateU5), Tỷ suất sinh (FertRate), và các chỉ số công nghệ, dân số khác lên tuổi thọ.
- Kỳ vọng kết quả là xác định được độ quan trọng của biến (feature importance) và thứ tự ảnh hưởng giảm dần của chúng.

1.2.2 Ứng dụng thực tiễn và chính sách

Báo cáo này được thiết kế để cung cấp bằng chứng khoa học có giá trị cao, có thể hỗ trợ việc ra quyết định ở cấp độ chính phủ và tổ chức quốc tế:

- **Hỗ trợ Chính phủ:** Giúp chính phủ ưu tiên các chính sách quan trọng nhất (như y tế, dân số, giáo dục) để tối đa hóa tác động lên tuổi thọ.
- **Hỗ trợ Tổ chức Quốc tế:** Giúp các tổ chức như Tổ chức Y tế Thế giới (WHO), Ngân hàng Thế giới (WB), hoặc Chương trình Phát triển Liên Hợp Quốc (UNDP) phân bổ nguồn lực tài chính và nhân lực hiệu quả hơn.
- **Phân tích ưu tiên đầu tư:** Báo cáo giúp trả lời câu hỏi chiến lược, ví dụ: Nếu việc giảm tỷ lệ tử vong trẻ em (MortRateU5) có tác động mạnh hơn việc tăng thu nhập bình quân đầu người (GNI/CapAtlas), thì khuyến nghị chính sách sẽ là đầu tư vào chăm sóc sức khỏe bà mẹ và trẻ em thay vì chỉ tập trung vào tăng trưởng kinh tế.

1.2.3 Mục tiêu kỹ thuật

Khảo sát tổng quan dữ liệu, bao gồm cấu trúc, phân bố và tính chất thống kê của các chỉ số quan trọng. Thực hiện thống kê mô tả và trực quan hóa (EDA) để hiểu rõ đặc điểm của dữ liệu:

- Thống kê mô tả và kiểm tra phân bố dữ liệu.
- Trực quan hóa dữ liệu.
- Xác định các yếu tố ảnh hưởng mạnh nhất.
- Chuẩn bị dữ liệu cho bài toán dự báo tuổi thọ trung bình (Life Expectancy) bằng cách xác định biến đầu vào tiềm năng.
- Xây dựng mô hình dự đoán: Linear Regression, SVM.

1.3 Phương pháp tiếp cận

Quy trình nghiên cứu được thực hiện theo 4 bước chính:

- **Bước 1: Tiền xử lý dữ liệu (Data Preprocessing)**
  Đây là bước quan trọng nhất để đảm bảo độ chính xác: Xử lý dữ liệu thiếu (Missing Values). Chuẩn hóa dữ liệu (Normalization): cần đưa các chỉ số về cùng một thước đo để mô hình không bị lệch.
- **Bước 2: Phân tích khám phá (EDA - Exploratory Data Analysis)**
  Sử dụng biểu đồ để tìm ra các mối quan hệ sơ bộ: Ma trận tương quan (Correlation Matrix) để xem biến nào có quan hệ mạnh nhất với tuổi thọ. Biểu đồ phân tán (Scatter Plot) để thấy rõ xu hướng (tuyến tính hay phi tuyến tính).
- **Bước 3: Xây dựng mô hình (Modeling)**
  Để lượng hóa mức độ ảnh hưởng và dự đoán tuổi thọ trung bình.
- **Bước 4: Kiểm định và Đánh giá**
  Sử dụng các chỉ số như R^2 (R-squared) để xem mô hình giải thích được bao nhiêu % sự biến động của tuổi thọ thực tế.

2 Cơ sở lý thuyết (Theoretical background)

2.1 Linear Regression

Linear Regression (Hồi quy tuyến tính) là một phương pháp thống kê dùng để mô hình hóa mối quan hệ giữa một biến phụ thuộc (dependent variable) y và một hoặc nhiều biến độc lập (independent variables) x. Mục tiêu chính là tìm ra một đường thẳng (hoặc siêu phẳng trong không gian nhiều chiều) khớp nhất với các điểm dữ liệu.

Phương trình tổng quát cho Simple Linear Regression (Hồi quy tuyến tính đơn biến) được biểu diễn như sau:

$$y = \theta_0 + \theta_1 x + \epsilon \tag{1}$$

Trong đó:

- y: Biến phụ thuộc (kết quả dự đoán).
- x: Biến độc lập (đầu vào).
- θ_0: Hệ số chặn (intercept/bias), giao điểm với trục tung.
- θ_1: Hệ số góc (slope/weight), thể hiện mức độ ảnh hưởng của x lên y.
- ϵ: Sai số (error term).

2.1.1 Phân loại Linear Regression

Dựa vào số lượng biến độc lập, ta có thể chia thành hai loại chính:

1. **Simple Linear Regression:** Chỉ có một biến độc lập x. Mối quan hệ được mô tả bằng một đường thẳng.
2. **Multiple Linear Regression:** Có nhiều biến độc lập $x_1, x_2, \ldots, x_n$. Phương trình có dạng:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

2.1.2 Best Fit Line và Hàm mất mát (Cost Function)

Mục tiêu của thuật toán là tìm ra "đường thẳng tốt nhất" (Best Fit Line) sao cho sai số giữa giá trị dự đoán và giá trị thực tế là nhỏ nhất. Để đo lường sai số này, ta sử dụng hàm mất mát, phổ biến nhất là **Mean Squared Error (MSE)**.

Công thức hàm mất mát $J(\theta)$:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2 \tag{2}$$

Trong đó:

- m: Số lượng mẫu dữ liệu training.
- $h_\theta(x^{(i)})$: Giá trị dự đoán cho mẫu thứ i.
- $y^{(i)}$: Giá trị thực tế của mẫu thứ i.

Việc tối ưu hóa mô hình chính là việc tìm bộ tham số $(\theta_0, \theta_1, \ldots)$ sao cho $J(\theta)$ đạt giá trị nhỏ nhất (min).

2.1.3 Gradient Descent

Để giảm thiểu hàm mất mát, Linear Regression thường sử dụng thuật toán tối ưu hóa gọi là **Gradient Descent**. Thuật toán này hoạt động bằng cách cập nhật lặp đi lặp lại các tham số θ theo hướng ngược lại với đạo hàm (gradient) của hàm mất mát.

Quy tắc cập nhật:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) \tag{3}$$

Trong đó α là *learning rate* (tốc độ học), quyết định bước nhảy của thuật toán trong mỗi lần lặp.

2.1.4 Cách tối ưu hóa trong thư viện `scikit-learn`

Trong khi một số phương pháp huấn luyện Linear Regression có thể sử dụng **Gradient Descent** để tối thiểu hóa hàm mất mát, thì trong thư viện `scikit-learn`, lớp `LinearRegression` **không sử dụng Gradient Descent**. Thay vào đó, mô hình được ước lượng bằng **nghiệm đóng (closed-form solution)** của bài toán bình phương tối thiểu, được giải thông qua phương pháp đại số tuyến tính là **Singular Value Decomposition (SVD)**.

Mục tiêu của mô hình là tối thiểu hóa hàm mất mát bình phương cho bài toán hồi quy đa biến:

$$J(\theta) = \frac{1}{2m} |X\theta - y|^2, \tag{4}$$

trong đó:

- $X \in \mathbb{R}^{m \times n}$: ma trận đặc trưng với m mẫu và n thuộc tính.
- $\theta \in \mathbb{R}^n$: vector tham số của mô hình.
- $y \in \mathbb{R}^m$: vector giá trị mục tiêu.

Nghiệm tối ưu trong OLS được cho bởi công thức đóng:

$$\theta^* = (X^T X)^{-1} X^T y, \tag{5}$$

nhưng `scikit-learn` không tính nghịch đảo ma trận trực tiếp để tránh:
mất ổn định số (numerical instability),
ma trận $X^T X$ có thể gần như suy biến (near-singular).
Thay vào đó, `scikit-learn` sử dụng bộ giải bình phương tối thiểu:

$$\theta^* = \text{lstsq}(X, y), \tag{6}$$

dựa trên **SVD**, cho phép:

- Ước lượng ổn định hơn,
- Tìm được nghiệm tối ưu ngay lập tức (không cần lặp),
- Không cần siêu tham số như learning rate hay số epoch.

Nhờ cách tiếp cận này, `LinearRegression` trong `scikit-learn` luôn tìm được nghiệm tối ưu toàn cục của bài toán hồi quy tuyến tính đa biến mà không cần phương pháp Gradient Descent.

2.1.5 Các giả định của Linear Regression

Để mô hình hoạt động hiệu quả, dữ liệu cần thỏa mãn một số giả định cơ bản:

- **Linearity:** Mối quan hệ giữa x và y phải là tuyến tính.
- **Homoscedasticity:** Phương sai của sai số là hằng số (không đổi dọc theo đường hồi quy).
- **Independence:** Các quan sát phải độc lập với nhau.
- **Normality:** Sai số tuân theo phân phối chuẩn.

2.2 SVR

Support Vector Regression (SVR) là một biến thể của thuật toán Support Vector Machine (SVM), được sử dụng cho các bài toán hồi quy. Không giống như Linear Regression cố gắng giảm thiểu sai số của tất cả các điểm dữ liệu (thường dẫn đến overfitting với nhiễu), SVR áp dụng một nguyên lý khác:

> *"Tìm một đường khớp với dữ liệu sao cho sai số nằm trong một ngưỡng chấp nhận được ϵ, đồng thời giữ cho mô hình phẳng nhất (ít phức tạp nhất) có thể."*

2.2.1 Các thành phần cốt lõi

Để hiểu cơ chế hoạt động của SVR, ta cần hình dung một "ống" (tube) bao quanh đường hồi quy:

- **Hyperplane (Siêu phẳng):** Đường trung tâm dùng để dự đoán giá trị y. Phương trình: $y = w^T x + b$.
- **ϵ-Insensitive Tube (Ống ϵ):** Một vùng an toàn có độ rộng 2ϵ bao quanh Hyperplane.
  - Mọi điểm dữ liệu nằm **bên trong** ống này được coi là dự đoán chính xác (sai số bằng 0).
  - Mô hình không bị phạt bởi các điểm nằm trong vùng này.
- **Boundary Lines (Biên):** Hai đường biên giới hạn ống ϵ, nằm tại vị trí $y = w^T x + b + \epsilon$ và $y = w^T x + b - \epsilon$.
- **Support Vectors:** Chỉ những điểm dữ liệu nằm **trên biên** hoặc **bên ngoài** ống ϵ mới được gọi là Support Vectors. Chỉ những điểm này mới ảnh hưởng đến việc xây dựng mô hình.

  [Image of Support Vector Regression diagram]

2.2.2 Mô hình Toán học

Mục tiêu của SVR không chỉ là giảm sai số, mà còn là tìm một hàm số "phẳng" nhất (để tránh overfitting). Điều này đạt được bằng cách tối thiểu hóa độ lớn của vector trọng số w.

Bài toán tối ưu hóa của SVR:

$$\min \frac{1}{2}||w||^2 \tag{7}$$

Với điều kiện ràng buộc (cho mọi điểm i):

$$|y_i - (w^T x_i + b)| \leq \epsilon \tag{8}$$

Điều này có nghĩa là ta muốn tìm đường thẳng sao cho sai số tuyệt đối của mọi điểm dữ liệu đều nhỏ hơn hoặc bằng ϵ.

2.2.3 Xử lý nhiễu: Biến bù (Slack Variables)

Trong thực tế, rất khó để mọi điểm dữ liệu đều nằm gọn trong ống ϵ. Để giải quyết vấn đề này (Soft Margin), SVR giới thiệu các **biến bù** ξ_i và ξ_i^* (Slack Variables).

- Các biến này đo lường khoảng cách vi phạm của các điểm nằm ngoài ống ϵ.
- Hàm mục tiêu mới sẽ bao gồm cả việc giảm thiểu các biến bù này:

$$\min \frac{1}{2}||w||^2 + C\sum_{i=1}^{m}(\xi_i + \xi_i^*) \tag{9}$$

Trong đó:

- C là **Hyperparameter** quan trọng:
  - C lớn: Phạt nặng các sai số (cố gắng khớp mọi điểm), dễ bị overfitting.
  - C nhỏ: Chấp nhận nhiều sai số hơn để có đường hồi quy mượt mà hơn (tăng khả năng tổng quát hóa).

2.2.4 Kernel Functions (Hàm nhân)

Sức mạnh thực sự của SVR nằm ở khả năng mô hình hóa dữ liệu phi tuyến tính bằng cách ánh xạ dữ liệu đầu vào không gian chiều thấp lên không gian chiều cao hơn, nơi chúng có thể phân tách tuyến tính.

Các loại Kernel phổ biến trong Scikit-learn:

1. **Linear Kernel:** $K(x, x') = x^T x'$
   - Dùng cho dữ liệu có quan hệ tuyến tính, tập dữ liệu lớn.
2. **Polynomial Kernel:** $K(x, x') = (\gamma x^T x' + r)^d$
   - Mô hình hóa các đường cong đa thức. Tham số d là bậc của đa thức.
3. **Radial Basis Function (RBF) Kernel:** $K(x, x') = \exp(-\gamma||x - x'||^2)$
   - Phổ biến nhất. Có thể mô hình hóa các đường cong phức tạp, khép kín.

2.3 Các chỉ số đánh giá mô hình Hồi quy (Regression Metrics)

Trong các bài toán hồi quy, việc xây dựng mô hình chỉ là bước đầu tiên. Để biết mô hình hoạt động tốt đến mức nào, ta cần sử dụng các chỉ số đánh giá (Evaluation Metrics) để đo lường sai số giữa giá trị dự đoán ($\hat{y}$) và giá trị thực tế (y).

Dưới đây là 3 chỉ số phổ biến nhất: MAE, RMSE và R-Squared.

2.3.1 Mean Absolute Error (MAE)

MAE (Sai số tuyệt đối trung bình) là trung bình cộng của giá trị tuyệt đối các sai số. Đây là cách đo lường trực quan nhất về độ lớn trung bình của lỗi dự đoán.

Công thức:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{10}$$

Trong đó:

- n: Số lượng mẫu dữ liệu.
- y_i: Giá trị thực tế.
- $\hat{y}_i$: Giá trị dự đoán.

Đặc điểm:

- Đơn vị của MAE giống với đơn vị của biến mục tiêu y, dễ giải thích.
- MAE đánh giá tất cả các sai số như nhau, do đó nó **ít nhạy cảm với các điểm dữ liệu nhiễu (outliers)** hơn so với RMSE.

2.3.2 Root Mean Squared Error (RMSE)

RMSE (Căn bậc hai của trung bình bình phương sai số) là chỉ số được sử dụng rất rộng rãi. Nó là căn bậc hai của MSE.

Công thức:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{11}$$

Đặc điểm:

- Giống như MAE, đơn vị của RMSE cũng cùng đơn vị với biến mục tiêu.
- Do bình phương sai số trước khi tính trung bình, RMSE **phạt rất nặng các sai số lớn**. Điều này làm cho RMSE nhạy cảm hơn với outliers. Nếu việc tránh các sai số lớn là ưu tiên hàng đầu, RMSE là lựa chọn tốt hơn MAE.

2.3.3 R-Squared (R^2 Score)

Khác với MAE và RMSE đo lường sai số tuyệt đối, R^2 (Hệ số xác định) đo lường mức độ phù hợp của mô hình so với mức độ biến thiên của dữ liệu. Nó cho biết bao nhiêu phần trăm sự biến thiên của biến phụ thuộc y được giải thích bởi các biến độc lập trong mô hình.

Công thức:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2} \tag{12}$$

Trong đó:

- SS_{res}: Tổng bình phương sai số dư (Residual Sum of Squares) - lỗi của mô hình.
- SS_{tot}: Tổng bình phương toàn phần (Total Sum of Squares) - độ biến thiên của dữ liệu so với giá trị trung bình $\bar{y}$.

Ý nghĩa giá trị:

- $R^2 = 1$: Mô hình dự đoán hoàn hảo mọi điểm dữ liệu.
- $R^2 = 0$: Mô hình không tốt hơn việc chỉ đoán giá trị trung bình $\bar{y}$ cho mọi trường hợp.
- $R^2 < 0$: Mô hình cực kỳ tệ (tệ hơn cả đoán trung bình).

3 Khám phá và tiền xử lý số liệu (Data Preparation and Exploration)

3.1 Tổng quan dữ liệu

3.1.1 Lựa chọn tập dữ liệu

Để đảm bảo kết quả phân tích có tính đại diện cao và phản ánh chính xác các mối quan hệ phức tạp tác động đến tuổi thọ trung bình, tập dữ liệu được sử dụng cần thỏa mãn ba tiêu chí cốt lõi:

1. **Tính toàn diện về không gian và thời gian:** bao gồm dữ liệu của đa dạng các quốc gia (phát triển và đang phát triển) trải dài qua nhiều năm để nhận diện rõ xu hướng biến động.
2. **Tính đa chiều của biến số:** phải bao hàm đầy đủ các nhóm yếu tố từ kinh tế vĩ mô, an sinh xã hội.
3. **Độ tin cậy nguồn tin:** dữ liệu phải được xác thực bởi các tổ chức quốc tế uy tín.

Dựa trên các tiêu chí này, nhóm nghiên cứu quyết định lựa chọn sử dụng tập dữ liệu *Global Socio-Economic & Demographic Insights*. Tập dữ liệu được cung cấp trên Kaggle và trích từ WDI của World Bank nên hoàn toàn có thể đảm bảo uy tín. Một ưu điểm nữa là tập dữ liệu này đã được làm sạch nên sẽ tiết kiệm thời gian thu thập và làm sạch dữ liệu thô.

Truy cập tập dữ liệu tại: Kaggle Link.

3.1.2 Giới thiệu tập dữ liệu

3.1.2.1 Nguồn gốc Tập dữ liệu được sử dụng mô tả thông tin về Kinh tế Xã hội & Dân số Toàn cầu (Global Socio-Economic & Demographic Insights Dataset). Tập dữ liệu này được xây dựng dựa trên các chỉ số phổ biến từ Chỉ số Phát triển Thế giới (World Development Indicators - WDI) của Ngân hàng Thế giới (World Bank).

3.1.2.2 Lí do chọn tập dữ liệu Việc lựa chọn tập dữ liệu được thúc đẩy bởi mục tiêu nghiên cứu rõ ràng và chất lượng dữ liệu:

- **Phù hợp với mục tiêu nghiên cứu:** Cung cấp các biến cần thiết để giải quyết câu hỏi trọng tâm: Xác định yếu tố kinh tế – xã hội nào ảnh hưởng mạnh nhất đến tuổi thọ trung bình.
- **Độ tin cậy và phạm vi toàn cầu:**
  - Nguồn gốc uy tín từ World Bank (WDI).
  - Phạm vi rộng: Khảo sát trên 202 quốc gia và vùng lãnh thổ, dữ liệu chuỗi thời gian từ 2000 đến 2021.

3.1.2.3 Phạm vi và Loại dữ liệu

- **Không gian:** 202 quốc gia và vùng lãnh thổ.
- **Thời gian:** 2000 - 2021.
- **Loại dữ liệu:** Dữ liệu dạng bảng (Tabular) và chuỗi thời gian (Time-series) đã được định dạng long format.
- **Đơn vị quan sát:** Mỗi hàng dữ liệu tương ứng với một cặp (Quốc gia, Năm).

3.1.2.4 Nội dung và các chỉ số Tập dữ liệu bao gồm 26 chỉ số bao phủ các khía cạnh kinh tế, xã hội, nhân khẩu học và công nghệ. Các cột dữ liệu (features) được mô tả chi tiết dưới đây:

Tên	**Kiểu**	**Đơn vị**	**Ý nghĩa**
Year	float	-	Năm thu thập dữ liệu
Country	string	-	Tên quốc gia
Region	string	-	Châu lục (vùng)
SubRegion	string	-	Tiểu khu vực
SurfAreaSqKm	float	km^2	Diện tích lãnh thổ
PopTotal	float	-	Tổng dân số
PopDens	float	p/km^2	Mật độ dân số
PopGrowth%	float	%	Tỷ lệ gia tăng dân số
GDP	float	USD	GDP bình quân đầu người
GDPGrowth%	float	%	Mức tăng trưởng GDP
AdolFertRate	float	%	Tỷ suất sinh của thanh thiếu niên
AgriValAdd%GDP	float	%	Giá trị gia tăng ngành nông nghiệp/GDP
Exports%GDP	float	%	Tỷ lệ xuất khẩu/GDP
FertRate	float	%	Tổng tỷ suất sinh
FDINetBoP	float	USD	Đầu tư trực tiếp nước ngoài
GNI/CapAtlas	float	USD	Tổng thu nhập quốc gia (GNI) đầu người
GNIAtlas	float	USD	Tổng thu nhập quốc gia
Imports%GDP	float	%	Tỷ lệ nhập khẩu/GDP
IndValAdd%GDP	float	%	Giá trị gia tăng ngành công nghiệp/GDP
InflConsPric%	float	%	Lạm phát hằng năm
LifeExpBirth	float	years	Tuổi thọ trung bình (Biến mục tiêu)
MerchTrade%GDP	float	%	Chỉ số mở cửa thương mại
MobileSubs/100	float	-	Số thuê bao di động/100 người
MortRateU5	float	%	Tỷ lệ tử vong trẻ dưới 5 tuổi
NetMigr	float	-	Di cư ròng
UrbanPopGrowth%	float	%	Tỷ lệ gia tăng dân số đô thị

3.2 Phân tích và khám phá dữ liệu (EDA)

3.2.1 Mục tiêu

Việc trực quan hoá dữ liệu giúp:

- Nhìn thấy, hiểu được sự phân bố của các biến trong tập dữ liệu.
- Phát hiện các giá trị ngoại lai (outliers).
- So sánh giữa các khu vực.
- Xác định mối quan hệ giữa các biến với biến mục tiêu Life Expectancy.

3.2.2 Kiểm tra dữ liệu thiếu (Missing value)

Nhóm nghiên cứu đã thực hiện kiểm tra tính toàn vẹn của dữ liệu trên toàn bộ 4.444 mẫu và 26 thuộc tính. Kết quả cho thấy tập dữ liệu đạt chất lượng cao, **không tồn tại bất kỳ giá trị khuyết** (null/missing values) nào ở các biến quan trọng.

3.2.3 Biểu đồ tương quan

Ma trận tương quan giữa các biến số (numerical variables) được thể hiện bằng heatmap để xác định các mối quan hệ tuyến tính.

```
# Loai bo cac bien khong phai so
numeric_df = df.select_dtypes(include=['float64', 'int64'])
corr = numeric_df.corr()
# Ve heatmap
plt.figure(figsize=(16, 12))
sns.heatmap(corr, cmap='coolwarm', annot=False)
plt.title("Correlation Heatmap of All Numerical Variables")
plt.show()
```

Listing 1: Code vẽ Ma trận tương quan

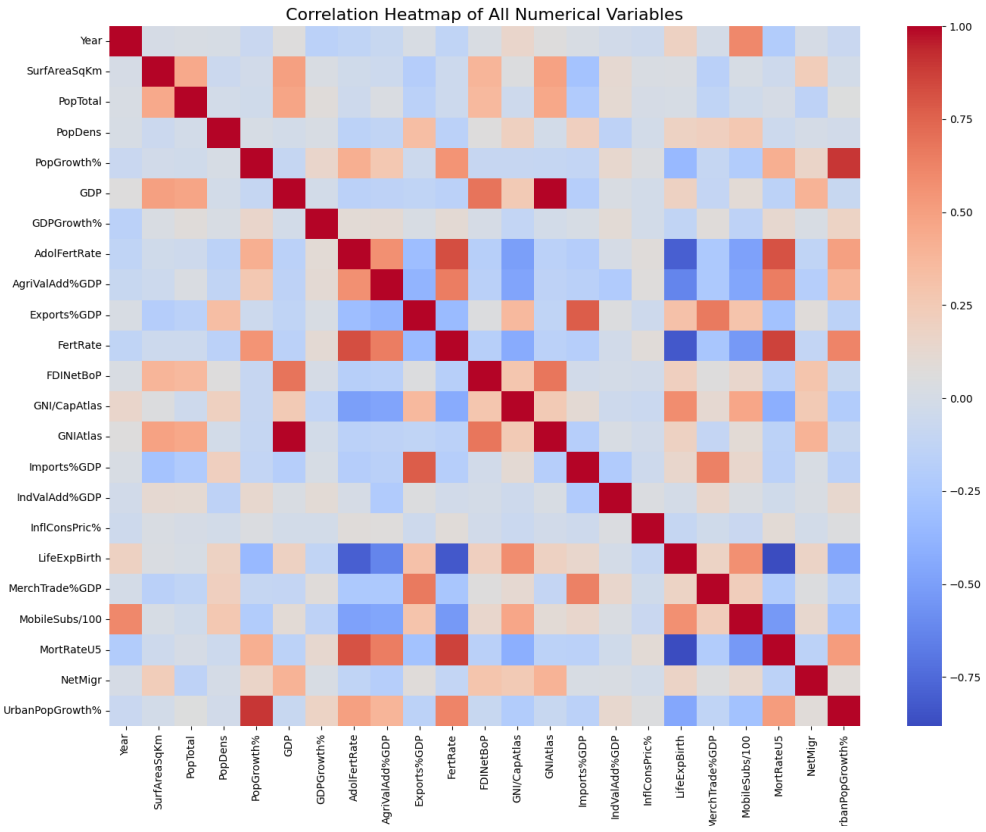

Hình 1: Biểu đồ tương quan giữa các biến

3.3 Tiền xử lý dữ liệu

3.3.1 Làm sạch dữ liệu

Kiểm tra Missing Value và Duplicates cho thấy tập dữ liệu sạch, không cần thực hiện gán dữ liệu (imputation).

3.3.2 Chia tập dữ liệu

Mục tiêu của bước này là thiết lập một quy trình chuẩn, lặp lại được để tách dữ liệu thành ba tập *Train*, *Validation* và *Test* sao cho:

- Mỗi tập phục vụ một mục tiêu rõ ràng (huấn luyện, tinh chỉnh/so sánh mô hình, đánh giá cuối cùng).
- Tránh rò rỉ thông tin (data leakage) giữa các giai đoạn.
- Giữ nguyên đặc tính phân phối cơ bản của dữ liệu (ví dụ phân phối theo Region, Year, hoặc theo mức thu nhập).
- Cho phép đánh giá công bằng giữa mô hình tuyến tính và mô hình phi tuyến (SVR).

Trong bài đồ án này, nhóm dự án chia tập dữ liệu thành 3 tập con với tỷ lệ **60%/ 20% / 20%** với các ràng buộc về *Region* và mức giá trị của *Life Expentancy*. Cụ thể:

- Khu vực địa lý (Region): Mỗi tập con đều phải bao gồm giá trị khảo sát của các vùng trên thế giới. Đồng thời tỷ lệ của chúng không chênh lệch quá nhiều
- Nhóm tuổi thọ (Low/Medium/High): Mỗi tập con đều phải bao gồm đầy đủ các mức giá trị cao thấp của Life Expentancy và tỷ lệ của chúng cũng không được chênh lệch quá nhiều giữa các tập.

Các yêu cầu trên được hiện thực ở `devide.py` như sau:

```python
# Stratification
df["LifeGroup"] = pd.qcut(df["LifeExpBirth"], 3, labels=["Low", "Medium", "High"])
df["Strata"] = df["Region"].astype(str) + "_" + df["LifeGroup"].astype(str)

# Train / Valid / Test Split
train_df, temp_df = train_test_split(
    df, test_size=0.4, stratify=df["Strata"], random_state=42
)

valid_df, test_df = train_test_split(
    temp_df, test_size=0.5, stratify=temp_df["Strata"], random_state=42
)
```

Listing 2: devide.py - Chia tập dữ liệu

Sau khi chia tập dự liệu, ta thu được các tập dữ liệu có kích thước như sau:

```
Train: (2666, 28)
Valid: (889, 28)
Test: (889, 28)
```

Về phân bố các ràng buộc trước đó.

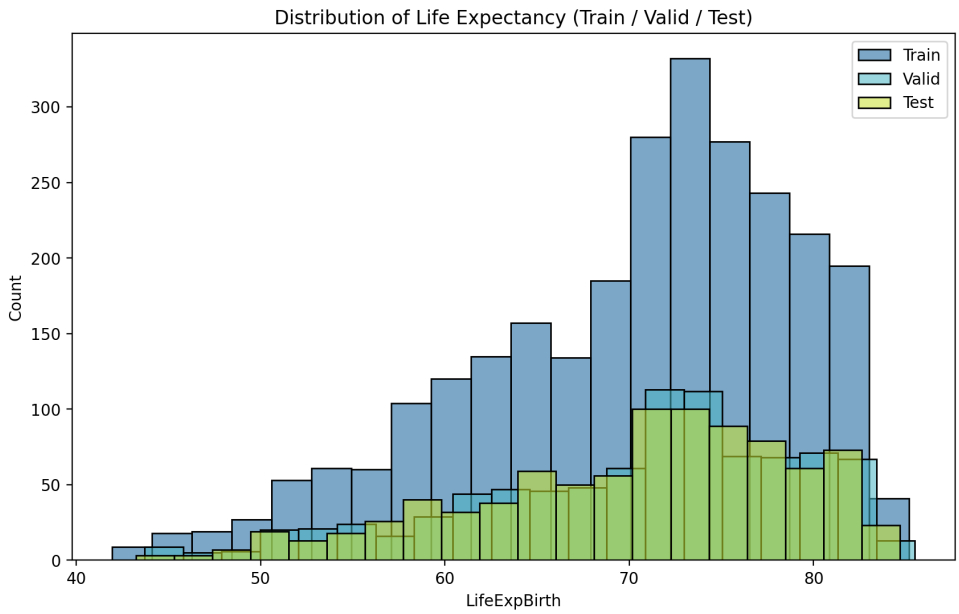

Hình 2: Phân bố tuổi thọ trung bình tại các tập Train - Valid - Test

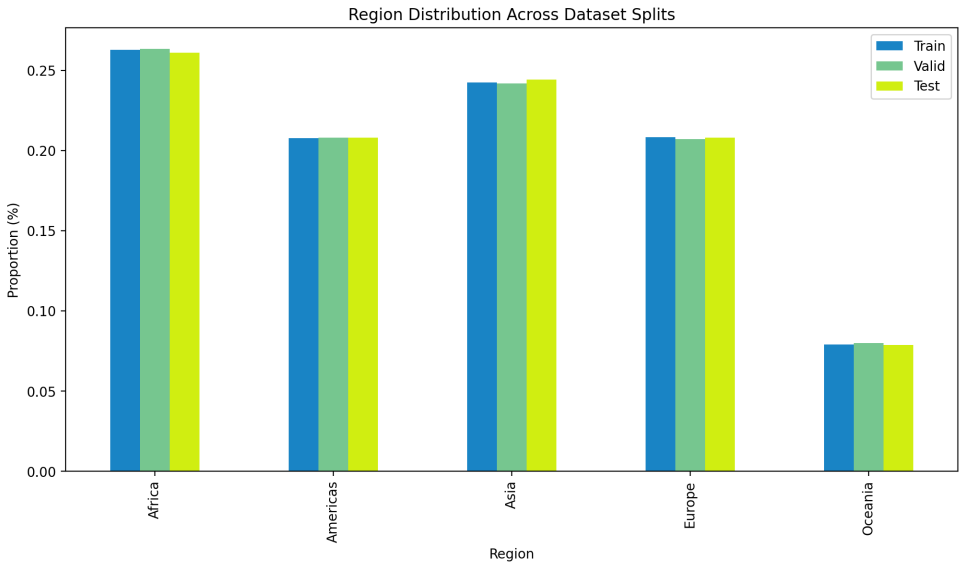

Hình 3: Phân bố vùng tại các tập Train - Valid - Test

3.3.3 Feature Selection

Trong các mô hình dự đoán tuổi thọ trung bình (Life Expectancy at Birth), việc lựa chọn biến đóng vai trò quan trọng nhằm đảm bảo mô hình vừa đạt độ chính xác cao, vừa có khả năng diễn giải rõ ràng cho các hàm ý kinh tế – xã hội. Dữ liệu gốc từ World Development Indicators chứa nhiều chỉ số kinh tế – xã hội khác nhau, trong đó không phải tất cả đều có đóng góp đáng kể đến biến mục tiêu. Do đó, nhóm dự án áp dụng quy trình Feature Selection theo phương pháp lọc dựa trên tương quan (Correlation-based Filtering) được tính toán ở phần trước đó.

$$Corr(x_i, \text{LifeExpBirth})$$

Khi xét giá trị tương quan của các biến:

- Tương quan dương: biến càng tăng → tuổi thọ tăng
- Tương quan âm: biến càng tăng → tuổi thọ giảm
- Nhưng cả hai đều mang ý nghĩa trong chọn biến

Do vậy, để chọn TOP 12 biến có mức tương quan tuyệt đối mạnh nhất, ta thêm trị cho công thức.

$$\text{Score}_i = |\text{Corr}(x_i, \text{LifeExpBirth})|$$

Hiện thực ở code:

```python
# Feature Selection
numeric_cols = train_df.select_dtypes(include=[np.number]).columns.tolist()
for c in [TARGET, 'Year']:
    if c in numeric_cols:
        numeric_cols.remove(c)

corrs = train_df[numeric_cols + [TARGET]].corr()[TARGET].abs().drop(TARGET).sort_values(
    ascending=False)
top_features = corrs.head(TOP_K).index.tolist()
print(f"\nTop {TOP_K} correlated features with {TARGET}:")
print(corrs.head(TOP_K))
```

```python

def prepare(df):
    df = df[top_features + [TARGET]].dropna()
    return df[top_features].values, df[TARGET].values

X_train, y_train = prepare(train_df)
X_valid, y_valid = prepare(valid_df)
X_test, y_test   = prepare(test_df)
```

Listing 3: main.py - Feature Selection

Giải thích quy trình:

1. Lọc Đặc trưng Số: Code trước hết xác định tất cả các cột dữ liệu số và loại bỏ biến mục tiêu (`TARGET`) cùng với cột `Year`.
2. Tính Tương quan: Tiếp theo, nó tính toán giá trị **tuyệt đối** của hệ số tương quan giữa từng đặc trưng số còn lại với `TARGET`.
3. Chọn Top K: Chỉ `TOP_K` đặc trưng có độ tương quan mạnh nhất được chọn (`top_features`).
4. Chuẩn bị Dữ liệu: Cuối cùng, hàm `prepare(df)` được sử dụng để lọc và làm sạch các tập dữ liệu *Train, Valid, và Test*, chỉ giữ lại các `top_features` đã chọn và loại bỏ các hàng có giá trị thiếu (`NaN`), đảm bảo dữ liệu sẵn sàng cho việc huấn luyện mô hình.

Kết quả thu được:

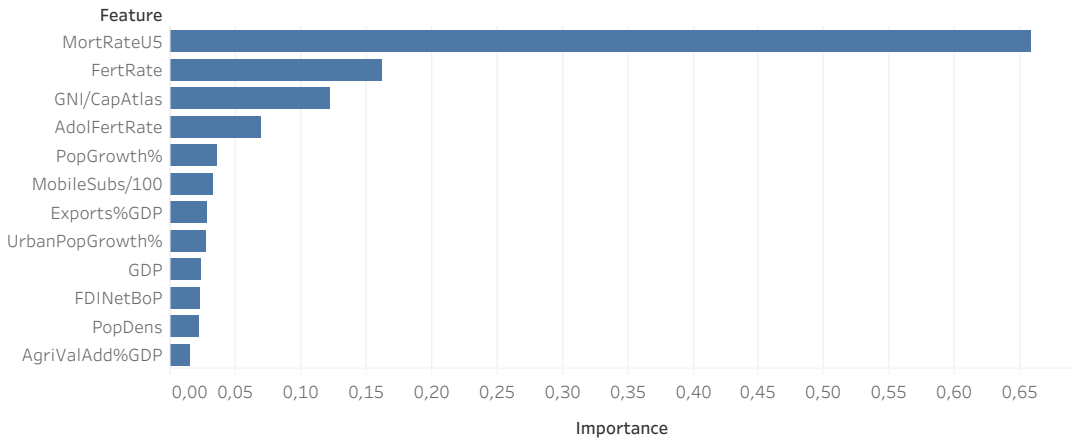

Hình 4: Top 12 features có mức ảnh hưởng cao nhất (SVR)

Dựa trên kết quả phân tích "Mean Permutation Importance" từ mô hình (xem Hình 4), ta có thể xác định các yếu tố ảnh hưởng mạnh nhất đến Tuổi thọ:

- **MortRateU5 (Tỷ lệ tử vong trẻ dưới 5 tuổi):** Đây là đặc trưng quan trọng nhất với trọng số vượt trội (> 0.6). Điều này hoàn toàn hợp lý về mặt thống kê và y tế, vì việc giảm tỷ lệ tử vong ở trẻ em có tác động trực tiếp và mạnh mẽ nhất đến việc tăng tuổi thọ trung bình của cả quần thể.
- **FertRate (Tỷ lệ sinh) & GNI/CapAtlas (GNI bình quân đầu người):** Đứng vị trí tiếp theo với mức độ ảnh hưởng khoảng 0.15 - 0.2. Điều này phản ánh xu hướng các quốc gia phát triển thường có thu nhập cao, tỷ lệ sinh thấp và hệ thống y tế tốt, dẫn đến tuổi thọ cao.
- Các yếu tố khác như *PopGrowth%* hay *MobileSubs* có ảnh hưởng thấp hơn đáng kể đối với mô hình.

4 Hiện thực mô hình nghiên cứu

4.1 Quy trình tiến hành

Trong đồ án, nhóm sinh viên tiến hành phân tích theo pipeline như sau:

1. **Chia tập dữ liệu**: chia dữ liệu thành ba phần độc lập gồm *Training set*, *Validation set* và *Test set* nhằm đảm bảo quá trình huấn luyện và đánh giá mô hình không bị chồng lấn thông tin.
2. **Lựa chọn biến (Feature Selection)**: chọn ra các biến có mức tương quan lớn nhất (theo trị tuyệt đối) với biến mục tiêu *Life Expectancy at Birth*, nhằm giảm chiều dữ liệu và tăng khả năng diễn giải mô hình.
3. **Chuẩn hóa dữ liệu**: áp dụng bộ chuẩn hóa *StandardScaler* để đưa toàn bộ các biến đầu vào về cùng thang đo (mean = 0, std = 1), từ đó đảm bảo mô hình học ổn định, đặc biệt với các thuật toán dựa trên khoảng cách như SVR.
4. **Huấn luyện mô hình**: xây dựng và huấn luyện hai mô hình gồm *Linear Regression* và *Support Vector Regression (SVR, kernel RBF)* trên tập dữ liệu đã chuẩn hóa.
5. **Chọn mô hình tối ưu**: sử dụng *Validation set* để so sánh hiệu năng hai mô hình theo các chỉ số R^2, RMSE và MAE, từ đó chọn ra mô hình có khả năng dự đoán tốt hơn.
6. **Đánh giá trên Test set**: đánh giá mô hình đã chọn trên *Test set* để kiểm tra khả năng tổng quát hóa và tránh hiện tượng overfitting.
7. **Các phân tích chuyên sâu**:
   - **Feature importance**: xác định mức độ đóng góp của từng biến.
   - **Multicollinearity (VIF)**: kiểm tra hiện tượng đa cộng tuyến giữa các biến đầu vào.
   - **Residual distribution**: phân tích phân phối phần dư để đánh giá độ lệch mô hình.
   - **Phân tích sai số**: xác định các mẫu có sai số dự đoán lớn nhất.
   - **Tương quan giữa residual và biến đầu vào**: kiểm tra xem phần dư còn mang thông tin hệ thống hay không.
8. **Kết luận và hàm ý chính sách**: tổng hợp các phát hiện quan trọng, rút ra bài học từ mô hình và đưa ra khuyến nghị dành cho cơ quan quản lý và tổ chức quốc tế liên quan.

Ngoài ra, pipeline trên cũng tương ứng với cấu trúc mã nguồn đã triển khai.

4.2 Phân tích đa cộng tuyến VIF

```
VIF:
            Feature          VIF
10              GDP  851.687144
11         GNIAtlas  843.373375
1          FertRate    6.370410
6   UrbanPopGrowth%    5.995298
7        PopGrowth%    5.654089
0        MortRateU5    4.941682
2      AdolFertRate    3.886526
3    AgriValAdd%GDP    2.081861
9         FDINetBoP    1.984464
4      GNI/CapAtlas    1.815566
```

```
5    MobileSubs/100    1.623071
8       Exports%GDP    1.400105
```

Listing 4: Result - Top 12 correlated features with LifeExpBirth

Kết quả kiểm tra hệ số phóng đại phương sai (VIF) ban đầu cho thấy sự tồn tại của hiện tượng đa cộng tuyến nghiêm trọng trong tập dữ liệu. Cụ thể, hai biến kinh tế vĩ mô là `GDP` (Tổng sản phẩm quốc nội) và `GNIAtlas` (Tổng thu nhập quốc gia) có chỉ số VIF cao bất thường, lần lượt là 851.69 và 843.37, vượt xa ngưỡng an toàn cho phép (thông thường $VIF < 10$). Điều này phản ánh sự tương quan tuyến tính gần như hoàn hảo giữa hai chỉ số này, gây nhiễu và làm mất ổn định hệ số hồi quy của mô hình. Các biến còn lại như `FertRate` hay `UrbanPopGrowth%` đều nằm trong ngưỡng chấp nhận được.

Để khắc phục vấn đề này và đảm bảo tính chính xác cho mô hình dự báo, nhóm nghiên cứu quyết định loại bỏ biến `GNIAtlas` khỏi tập dữ liệu huấn luyện. Lý do là biến này mang thông tin tương tự với `GDP`, việc giữ lại cả hai là dư thừa (redundant). Thu được kết quả như sau:

```
VIF:
            Feature       VIF
1          FertRate  6.465498
6   UrbanPopGrowth%  5.989262
7        PopGrowth%  5.670899
0        MortRateU5  5.196509
2      AdolFertRate  3.903552
3    AgriValAdd%GDP  2.083652
10              GDP  2.044534
9         FDINetBoP  1.948992
4      GNI/CapAtlas  1.812823
5    MobileSubs/100  1.712674
8       Exports%GDP  1.467589
11          PopDens  1.225968
```

Listing 5: Result - Top 12 correlated features with LifeExpBirth after remove GNI

Sau khi loại bỏ biến gây nhiễu, bảng kết quả VIF mới (Listing 5) cho thấy sự cải thiện rõ rệt:

- Chỉ số VIF của biến `GDP` giảm mạnh từ hơn 851 xuống còn 2.04, chứng tỏ hiện tượng đa cộng tuyến đã được giải quyết triệt để.
- Biến có VIF cao nhất hiện tại là `FertRate` (6.47), vẫn nằm hoàn toàn trong ngưỡng an toàn ($VIF < 10$).
- Tất cả các biến độc lập còn lại đều có hệ số VIF thấp, đảm bảo sự độc lập cần thiết để xây dựng mô hình hồi quy tuyến tính và SVR tin cậy.

Kết luận: Tập đặc trưng sau khi xử lý (gồm 12 biến trong Listing 5) đủ điều kiện để đưa vào huấn luyện mô hình.

4.3 Huấn luyện và kiểm thử mô hình

Trong bước này, nhóm dự án sử dụng hai thuật toán dự báo được làm rõ trước đó để huấn luyện mô hình.

- Linear Regression – mô hình tuyến tính truyền thống, giải thích được và nhẹ.
- SVR (Support Vector Regression) với kernel RBF – mô hình phi tuyến cho khả năng mô tả quan hệ phức tạp.

4.3.1 Huấn luyện mô hình

Sau khi hoàn tất bước chuẩn hóa dữ liệu, dữ liệu được huấn luyện như sau:

```python
# Linear Regression Training
lr = LinearRegression()
lr.fit(X_train_scaled, y_train)
y_pred_valid_lr = lr.predict(X_valid_scaled)
metrics_lr_valid = metrics(y_valid, y_pred_valid_lr)
print("\nLinear Regression (Validation):", metrics_lr_valid)

# SVR Training
svr = SVR(kernel='rbf', C=1.0, gamma='scale', epsilon=0.1)
svr.fit(X_train_scaled, y_train)
y_pred_valid_svr = svr.predict(X_valid_scaled)
metrics_svr_valid = metrics(y_valid, y_pred_valid_svr)
print("\nSVR (Validation):", metrics_svr_valid)
```

Listing 6: main.py - Huấn luyện và kiểm thử mô hình (Model Training and Validation)

Giải thích: `lr.fit()` và `svr.fit()` dùng dữ liệu huấn luyện để học tham số mô hình. `predict()` dự đoán trên Validation set.

Hàm `metrics()` tính 3 chỉ số đánh giá:

- R^2 (Coefficient of determination) – mức độ mô hình giải thích được phương sai của dữ liệu.
- RMSE (Root Mean Square Error) – sai số trung bình theo đơn vị gốc (nặng lỗi lớn).
- MAE (Mean Absolute Error) – sai số tuyệt đối trung bình (nhẹ hơn RMSE).

4.3.2 Kiểm thử mô hình

```
                                        R2     RMSE      MAE
Linear Regression (Valid)   0.8535   3.4306   2.4467
SVR (Valid)                 0.8825   3.0733   2.1268
```

Listing 7: Result - Kết quả kiểm thử trên tập Validation

Nhận xét: Hai mô hình được huấn luyện gồm *Linear Regression* và *SVR (RBF kernel)*. Kết quả cho thấy sự khác biệt đáng kể về chất lượng dự đoán:

(1) Linear Regression:

Mô hình đạt `R² = 0.8535`, giải thích được khoảng 85% biến thiên của tuổi thọ. Tuy nhiên, các chỉ số `RMSE = 3.4306` và `MAE = 2.4467` cho thấy sai số dự đoán trung bình còn tương đối cao. Điều này phản ánh hạn chế của mô hình tuyến tính khi quan hệ giữa các yếu tố kinh tế – xã hội và tuổi thọ có tính phi tuyến.

(2) SVR:

SVR thể hiện hiệu quả vượt trội hơn với `R² = 0.8825`, cao hơn Linear Regression gần 3%. Đồng thời, mô hình đạt `RMSE = 3.0733` và `MAE = 2.1268`, chứng tỏ sai số thấp hơn và ổn định hơn. Nhờ khả năng nắm bắt các quan hệ phi tuyến qua RBF kernel, SVR phù hợp hơn với dữ liệu có cấu trúc phức tạp.

(3) Kết luận lựa chọn mô hình:

Với hiệu suất tốt hơn trên toàn bộ chỉ số, `SVR được chọn làm mô hình chính cho bước đánh giá cuối cùng trên Test Set`.

```
Model Selected: SVR
```

Listing 8: Result - Kết quả lựa chọn mô hình tối ưu

4.4 Kiểm định mô hình

```python
y_pred_test = chosen_model.predict(X_test_scaled)
metrics_test = metrics(y_test, y_pred_test)
print(f"\n Test Performance ({model_name}):")
print(pd.Series(metrics_test).round(4))
```

Listing 9: Result - main.py - Test Module

```
Test Performance (SVR):
R2      0.8862
RMSE    2.9035
MAE     2.0099
dtype: float64
```

Listing 10: Result - Kết quả kiểm định mô hình

Sau khi lựa chọn SVR là mô hình tối ưu dựa trên tập validation, mô hình được đánh giá lần cuối trên tập **test** – vốn được giữ tách biệt hoàn toàn khỏi quá trình huấn luyện và chọn mô hình. Kết quả thu được:

- $R^2 = 0.8862$: Mô hình giải thích được khoảng **88.6% biến thiên** của tuổi thọ trung bình ở tập dữ liệu chưa từng thấy. Đây là mức độ phù hợp cao, cho thấy khả năng tổng quát hóa tốt.
- RMSE = 2.9035: Sai số căn phương bình phương chỉ ở mức **$\tilde{2}$.90 năm**, thấp hơn so với validation, cho thấy mô hình ổn định và không bị overfitting.
- MAE = 2.0099: Sai số tuyệt đối trung bình khoảng **2.0 năm**, nghĩa là dự đoán của mô hình nhìn chung chỉ lệch thực tế khoảng 1.5–2 năm, một mức sai số được xem là tốt đối với dữ liệu nhân khẩu học.

Tổng thể, kết quả kiểm định khẳng định rằng *SVR không chỉ hoạt động tốt trên validation mà còn duy trì hiệu suất cao trên test*, chứng minh tính đáng tin cậy của mô hình và mức rủi ro overfitting thấp. Mô hình đủ mạnh để tiếp tục sử dụng trong phân tích yếu tố ảnh hưởng và hỗ trợ hoạch định chính sách.

4.5 Residual Analysis

4.5.1 Phân tích sai số

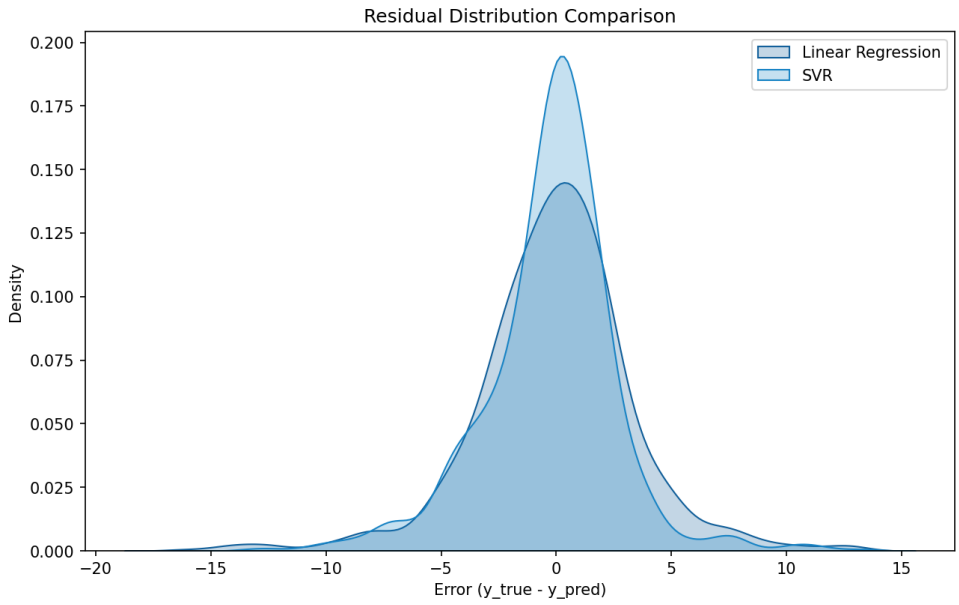

Hình 5: Biểu đồ sai số của 2 mô hình

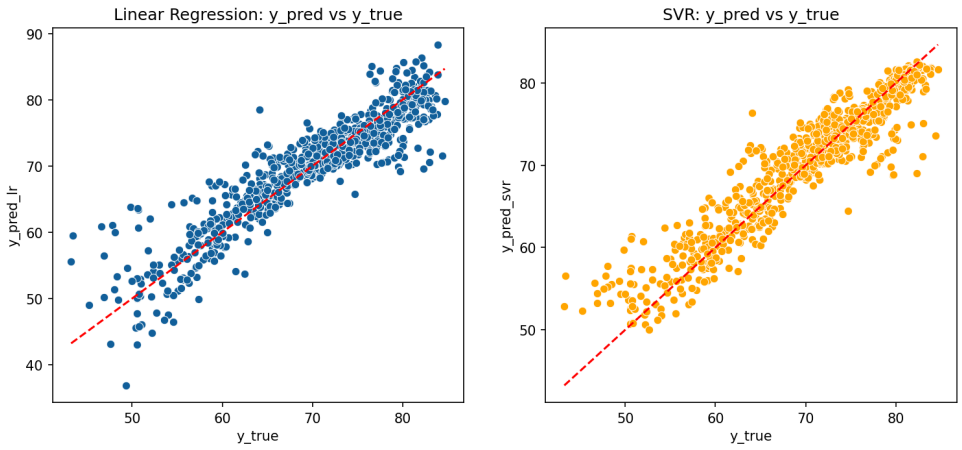

Hình 6: Phân bố giá trị của 2 mô hình và giá trị thực tế

4.5.2 Các mẫu có sai số lớn

	Country	Year	y_true	y_pred_lr	error_lr	abs_error_lr
596	Zimbabwe	2003.0	43.393000	59.504351	-16.111351	16.111351
490	Cayman Islands	2011.0	64.097280	78.464281	-14.367001	14.367001
164	Eswatini	2010.0	46.619000	60.880821	-14.261821	14.261821
259	Eswatini	2012.0	49.835000	63.857576	-14.022576	14.022576
302	Lesotho	2012.0	47.835000	61.094675	-13.259675	13.259675
512	Botswana	2002.0	50.632000	63.609313	-12.977313	12.977313
461	Liechtenstein	2021.0	84.402439	71.573320	12.829119	12.829119
195	Botswana	2001.0	50.676000	63.445511	-12.769511	12.769511
208	French Polynesia	2015.0	82.354000	69.633426	12.720574	12.720574
31	Niger	2000.0	49.322000	36.883772	12.438228	12.438228

Listing 11: Các mẫu có sai số lớn nhất của Linear Regression

```
              Country    Year     y_true  y_pred_svr  error_svr  abs_error_svr
208  French Polynesia  2015.0  82.354000   69.003616  13.350384      13.350384
596          Zimbabwe  2003.0  43.393000   56.562651 -13.169651      13.169651
490    Cayman Islands  2011.0  64.097280   76.396695 -12.299415      12.299415
832  French Polynesia  2019.0  82.996000   71.127423  11.868577      11.868577
880  French Polynesia  2005.0  79.736000   68.864291  10.871709      10.871709
828  French Polynesia  2003.0  79.703000   68.833886  10.869114      10.869114
461     Liechtenstein  2021.0  84.402439   73.593134  10.809305      10.809305
195          Botswana  2001.0  50.676000   61.404379 -10.728379      10.728379
512          Botswana  2002.0  50.632000   61.041203 -10.409203      10.409203
783           Curacao  2006.0  74.709756   64.484015  10.225741      10.225741
```

Listing 12: Các mẫu có sai số lớn nhất của SVR

```
Residual Stats (LR): {'mean': np.float64(-0.08701278893686881), 'std': np.float64
    (3.4105001716354804), 'skewness': np.float64(-0.35655101485888), 'kurtosis': np.
    float64(3.0329728848635273)}
Residual Stats (SVR): {'mean': np.float64(-0.26625919816591964), 'std': np.float64
    (2.8912798335571974), 'skewness': np.float64(-0.17313996713674404), 'kurtosis': np.
    float64(3.127834327878288)}
```

Listing 13: Các mẫu có sai số lớn nhất của SVR

Có thể thấy, kết quả phân tích các trường hợp dự đoán sai lệch lớn nhất cho thấy sự khác biệt rõ rệt giữa hai mô hình Linear Regression và SVR trong khả năng xử lý dữ liệu có quan hệ phi tuyến và phân phối không đồng đều.

Đối với Linear Regression: Sai số lớn nhất của Linear Regression tập trung mạnh vào các nước châu Phi thu nhập thấp (Zimbabwe, Eswatini, Lesotho). Các mẫu có tuổi thọ thực tế rất thấp (khoảng 43–50 năm) thường bị dự đoán cao hơn thực tế từ 13 đến 16 năm. Ngược lại, một số trường hợp có tuổi thọ rất cao (trên 82 năm) lại bị dự đoán thấp từ 12 đến 13 năm. Mô hình tuyến tính có xu hướng kéo các điểm dữ liệu cực trị về giá trị trung bình, dẫn đến sai số lớn ở hai đầu của phân phối tuổi thọ. Điều này phù hợp vì Linear Regression giả định quan hệ tuyến tính ổn định, trong khi dữ liệu từ các quốc gia này có:

- Quan hệ phi tuyến mạnh giữa thu nhập, chi tiêu y tế và tuổi thọ
- Nhiều "điểm gãy" (structural breaks) do dịch bệnh hoặc thay đổi chính sách
- Mức tuổi thọ thấp hơn hẳn mặt bằng chung

→ Mô hình tuyến tính không đủ linh hoạt để nắm bắt các biến động này, dẫn đến overprediction (dự đoán cao hơn thực tế) từ 12–16 năm.

Đối với SVR: Các mẫu có sai số lớn đều nằm ở nhóm tuổi thọ rất cáo hoặc rất thấp như Linear Regression. Tuy nhiên, giá trị sai số nhỏ hơn, chỉ dao động từ 10 - 13 năm. Đồng thời, các mẫu sai nhiều nhất của SVR lại tập trung vào **French Polynesia** và một số lãnh thổ nhỏ. Lý do:

- SVR (kernel RBF) mô hình hóa tốt phi tuyến, xử lý tốt nhóm nước châu Phi có biến động phức tạp
- Tuy nhiên, SVR nhạy cảm với mẫu "lạ" (outlier theo kiểu quốc gia nhỏ, dân số ít)
- Các vùng lãnh thổ như French Polynesia có xu hướng khác biệt rõ, không nằm gần "biên" của phân phối huấn luyện

→ SVR underpredict tuổi thọ của các quốc gia thu nhập cao nhỏ lẻ như French Polynesia và Liechtenstein.

Việc phân tích các trường hợp dự báo sai lệch nhiều nhất giúp nhận diện các yếu tố ngoại lai (outliers) mà mô hình chưa bao quát hết. Bảng **??** liệt kê các quốc gia có sai số lớn nhất từ mô hình SVR trên tập Test.

4.6 Tương quan giữa Residual và biến đầu vào

Để kiểm tra xem mô hình có bỏ sót thông tin quan trọng nào từ dữ liệu hay không, nhóm đã vẽ biểu đồ phân tán giữa phần dư (Residuals) và các biến đầu vào quan trọng (như MortRateU5, GNI).

.

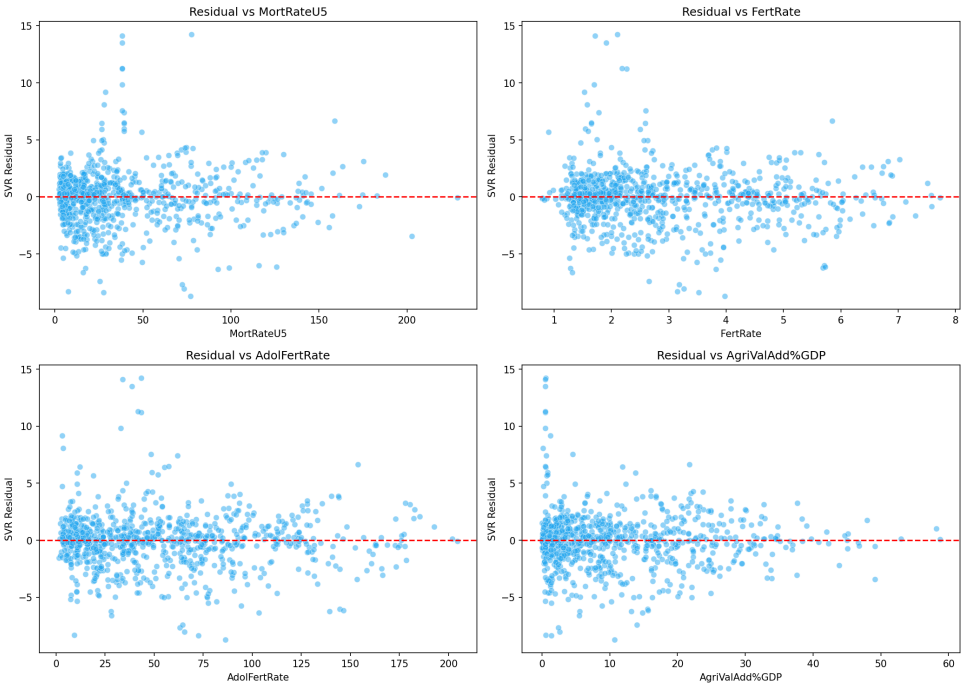

Hình 7: Biểu đồ tương quan giữa phần dư và các biến đặc trưng

Nhận xét: Các điểm dữ liệu phân bố ngẫu nhiên xung quanh trục tung độ 0 và không tạo thành bất kỳ quy luật hay hình dáng đặc biệt nào (như parabol hay đường thẳng dốc). Điều này chứng tỏ mô hình SVR đã khai thác tốt các mối quan hệ phi tuyến trong dữ liệu và phần sai số còn lại mang tính ngẫu nhiên (white noise).

5 Trực quan hoá dữ liệu với Dashboard

5.1 Thiết kế Dashboard

Sản phẩm cuối cùng là Dashboard được xây dựng trên Tableau bao gồm:

- **Dashboard 1 (Tổng quan EDA):** Bản đồ thế giới thể hiện tuổi thọ từng quốc gia, biểu đồ tốc độ tăng trưởng tuổi thọ theo năm của từng khu vực, Box plot của từng khu vực và biểu đồ thể hiện mối quan hệ phi tuyến giữa các biến quan trọng đối với biến mục tiêu tuổi thọ trung bình.
- **Dashboard 2 (Kết quả):** Biểu đồ cột dạng ngang thể hiện những yếu tố ảnh hưởng đến biến mục tiêu tuổi thọ trung bình, biểu đồ so sánh tương quan giá trị dự đoán và giá trị thực với trục chuẩn y = x và biểu đồ cột thể hiện đánh giá hai mô hình thông qua 2 chỉ số R2 và RMSE

Truy cập Dashboard tương tác **tại đây**.

5.2 Các Insight rút ra

5.2.1 EDA Dashboard

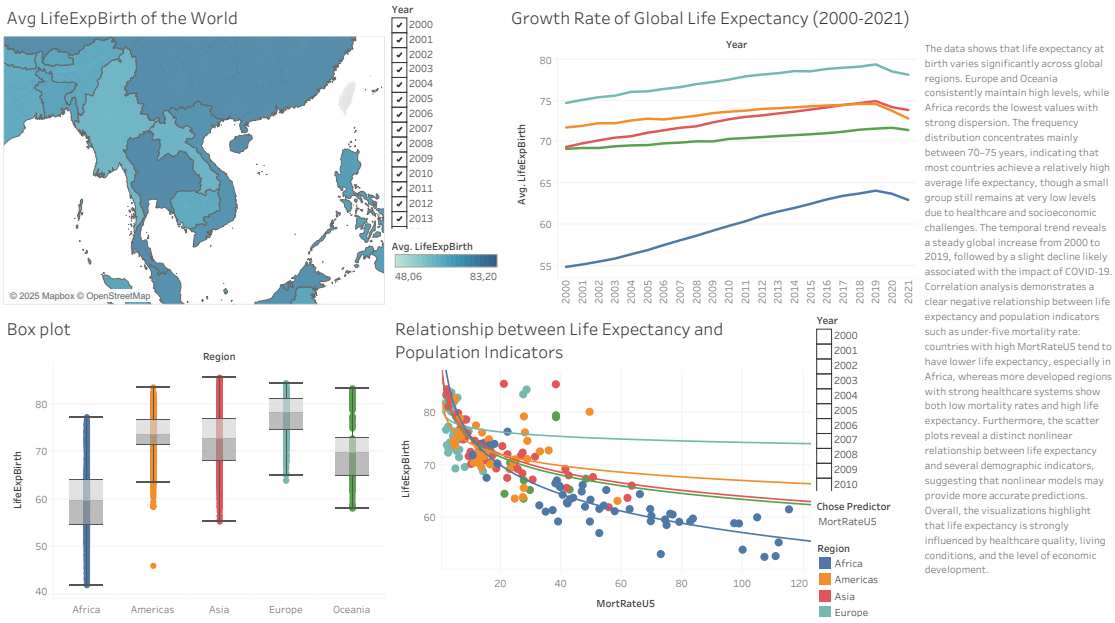

Hình 8: EDA Dashboard

Biểu đồ 1: Phân bố tuổi thọ theo địa lý

Dữ liệu hiển thị sự phân hóa rõ rệt về tuổi thọ giữa các châu lục. Trong khi Europe và Oceania dẫn đầu với mức tuổi thọ cao từ 75 đến 83 tuổi, thì Africa lại là khu vực có chỉ số thấp nhất, dao động từ 48 đến 60 tuổi. Khu vực Asia và Americas nằm trong nhóm trung bình khá nhưng lại ghi nhận độ phân hóa lớn giữa các quốc gia giàu và nghèo. Thực trạng này phản ánh vai trò quyết định của chất lượng hệ thống y tế, thu nhập quốc gia và điều kiện sống đối với tuổi thọ người dân.

Biểu đồ 2: Xu hướng tăng trưởng tuổi thọ của các châu lục từ 2000 đến 2021

Biểu đồ xu hướng cho thấy tín hiệu tích cực khi tất cả các châu lục đều duy trì đà tăng trưởng tuổi thọ ổn định trong giai đoạn 2000–2019. Đáng chú ý, Châu Phi là khu vực có tốc độ tăng trưởng nhanh nhất, minh chứng cho hiệu quả của các nỗ lực cải thiện y tế cơ bản. Tuy nhiên, giai đoạn 2020–2021 ghi nhận sự sụt giảm tuổi thọ đồng loạt ở mọi khu vực, phản ánh rõ nét tác động tiêu cực của đại dịch COVID-19 và cho thấy sự tổn thương của các hệ thống y tế trước những cú sốc toàn cầu.

Biểu đồ 3: Biểu đồ tập phân bố giá trị tuổi thọ trung bình theo châu lục

Biểu đồ hộp (Boxplot) làm nổi bật sự khác biệt về cấu trúc xã hội giữa các khu vực. Europe và Oceania có trung vị cao và độ phân tán thấp, cho thấy một hệ thống y tế phát triển đồng đều và ổn định. Ngược lại, Asia và Americas có độ phân tán lớn, phản ánh sự đa dạng và chênh lệch kinh tế - xã hội sâu sắc. Riêng Africa có trung vị thấp và xuất hiện nhiều điểm ngoại lai (outliers), biểu thị sự thiếu ổn định và bất bình đẳng nội vùng nghiêm trọng.

Biểu đồ 4: Mối quan hệ giữa Tuổi thọ trung bình với các chỉ số kinh tế đầu vào (Đại diện: `MortRateU5`)

Biểu đồ phân tán giữa `LifeExpBirth` và `MortRateU5` xác nhận mối quan hệ âm phi tuyến rất mạnh mẽ. Các quốc gia có tỷ lệ tử vong trẻ em (`MortRateU5`) cao đều có tuổi thọ thấp, với cụm dữ liệu của khu vực Africa tách biệt rõ ràng. Điều này khẳng định rằng việc giảm thiểu tử vong ở trẻ em chính là chìa khóa cốt lõi để nâng cao tuổi thọ quốc gia.

5.2.2 Dashboard mô tả mô hình được huấn luyện

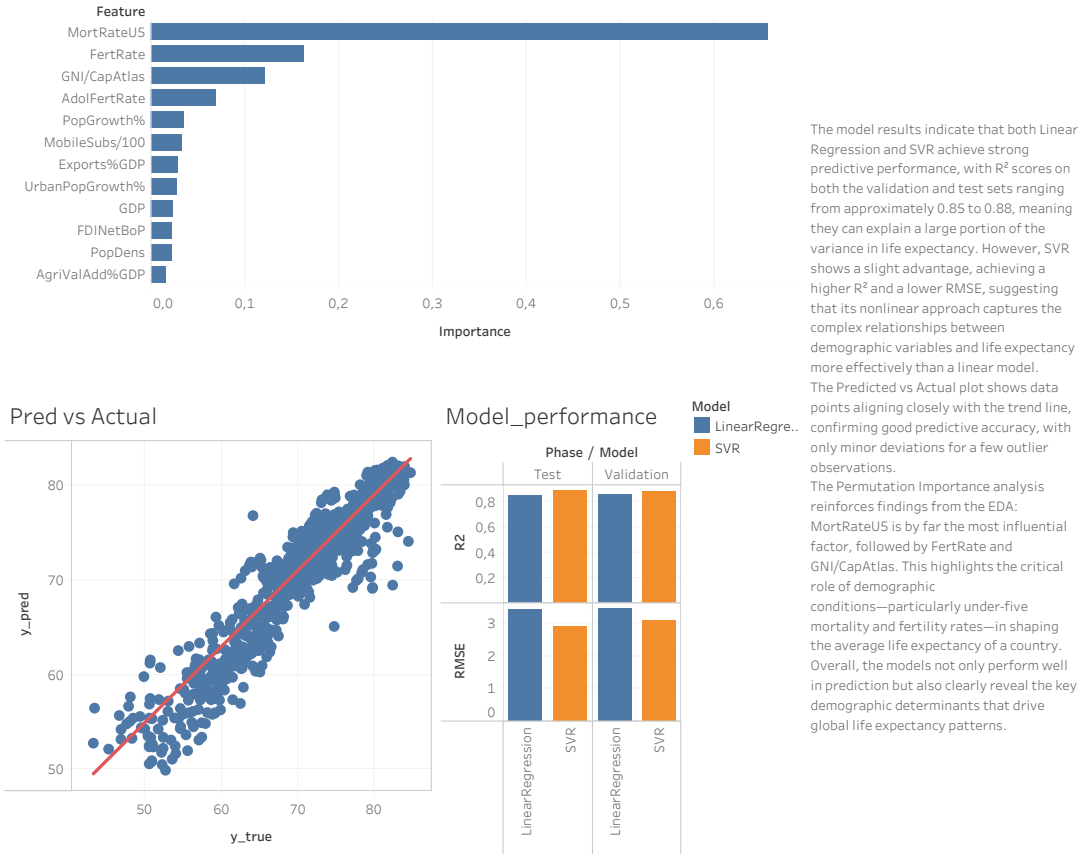

Hình 9: Models Result Dashboard

Biểu đồ 1. Phân tích Tầm quan trọng của biến (Permutation Importance):

- **MortRateU5 (Tỷ lệ tử vong trẻ dưới 5 tuổi):** Đây là đặc trưng quan trọng nhất với trọng số vượt trội (> 0.6). Điều này hoàn toàn hợp lý về mặt thống kê và y tế, vì việc giảm tỷ lệ tử vong ở trẻ em có tác động trực tiếp và mạnh mẽ nhất đến việc tăng tuổi thọ trung bình của cả quần thể.
- **FertRate (Tỷ lệ sinh) & GNI/CapAtlas (GNI bình quân đầu người):** Đứng vị trí tiếp theo với mức độ ảnh hưởng khoảng 0.15 - 0.2. Điều này phản ánh xu hướng các quốc gia phát triển thường có thu nhập cao, tỷ lệ sinh thấp và hệ thống y tế tốt, dẫn đến tuổi thọ cao.
- Các yếu tố khác như *PopGrowth%* hay *MobileSubs* có ảnh hưởng thấp hơn đáng kể đối với mô hình.

Biểu đồ 2. So sánh giá trị mô hình dự đoán và giá trị thực tế

Biểu đồ phân tán giữa giá trị dự đoán và thực tế của SVR cho thấy các điểm dữ liệu tập trung sát đường $y = x$, chứng tỏ sai lệch dự báo nhỏ. Một số ít điểm ngoại lai (outliers) nằm xa đường tham chiếu chủ yếu thuộc về các quốc gia chịu ảnh hưởng bởi chiến tranh, nghèo đói hoặc khủng hoảng y tế. Nhìn chung, mô hình thể hiện sự ổn định cao và đáng tin cậy cho các dự báo trong tương lai.

Biểu đồ 3. So sánh hiệu suất các mô hình dự đoán

Kết quả thực nghiệm cho thấy cả hai mô hình Linear Regression và SVR đều đạt hiệu suất dự đoán tốt với R^2 dao động trong khoảng 0.85–0.88 và sai số RMSE thấp xấp xỉ 3.0. Tuy nhiên, SVR chứng tỏ sự vượt trội với chỉ số R^2 cao hơn và RMSE thấp hơn. Sự chênh lệch này chỉ ra rằng dữ liệu tuổi thọ có mối quan hệ phi tuyến phức tạp với các biến đầu vào, điều mà SVR (với RBF kernel) có khả năng nắm bắt tốt hơn so với mô hình tuyến tính truyền thống.

6 Kết luận và Hướng phát triển

6.1 Kết luận

Đồ án đã xây dựng thành công quy trình phân tích dữ liệu khép kín để dự báo tuổi thọ trung bình. Kết quả thực nghiệm cho thấy mô hình **SVR (Kernel RBF)** thể hiện tính **ưu việt** rõ rệt so với **Linear Regression**, với chỉ số R^2 cao hơn khoảng 3%. Sự chênh lệch hiệu suất này chủ yếu xuất phát từ khả năng của SVR trong việc xử lý hiệu quả các mối quan hệ phi tuyến phức tạp, điển hình là mối quan hệ dạng Logarit giữa Thu nhập bình quân và Tuổi thọ. Bên cạnh đó, nghiên cứu cũng xác định được rằng **Tỷ lệ tử vong trẻ em dưới 5 tuổi (MortRateU5)** và **Tỷ suất sinh (FertRate)** là hai yếu tố kinh tế - xã hội có tác động mạnh mẽ nhất đến tuổi thọ trung bình của một quốc gia.

6.2 Hạn chế và Hướng phát triển

Mặc dù đạt được những kết quả khả quan, mô hình hiện tại vẫn tồn tại một số hạn chế nhất định. Đáng chú ý là sai số dự báo có xu hướng tăng cao đối với các nhóm quốc gia chịu ảnh hưởng bởi các biến động bất thường (như chiến tranh, dịch bệnh) hoặc có quy mô dân số quá nhỏ, làm giảm tính đại diện của dữ liệu. Ngoài ra, độ chính xác của mô hình cũng bị giới hạn do bộ dữ liệu đầu vào chưa bao gồm các chỉ số chuyên sâu về hệ thống y tế, chẳng hạn như số lượng bác sĩ hay số giường bệnh trên đầu người.

Để khắc phục các nhược điểm trên và cải thiện hiệu suất dự báo trong tương lai, hướng nghiên cứu tiếp theo sẽ tập trung vào việc thử nghiệm các mô hình Ensemble Learning hiện đại như **Random Forest**, **XGBoost** hoặc tiếp cận các kiến trúc **Deep Learning**. Đồng thời, việc bổ sung các nguồn dữ liệu định tính về tình hình chính trị - xã hội sẽ là bước đi cần thiết giúp mô hình nắm bắt tốt hơn các yếu tố ngoại lai và tăng cường độ ổn định trong thực tế.

7 Tài liệu tham khảo (Reference)

[1] GeeksforGeeks. *Linear Regression (Python Implementation).*
https://www.geeksforgeeks.org/machine-learning/ml-linear-regression/

[2] GeeksforGeeks. *Support Vector Machine Algorithm.*
https://www.geeksforgeeks.org/machine-learning/support-vector-machine-algorithm/

[3] GeeksforGeeks. *Support Vector Regression (SVR) using linear and non-linear kernels in Scikit Learn.*
https://www.geeksforgeeks.org/machine-learning/support-vector-regression-svr-using-linear-and-no

[4] GeeksforGeeks. *Metrics for Machine Learning Model.*
https://www.geeksforgeeks.org/machine-learning/metrics-for-machine-learning-model/

[5] Samy Baladram. *Global Socio-Economic & Demographic Insights.*
https://www.kaggle.com/datasets/samybaladram/databank-world-development-indicators

[6] Midou Azerty. *GDP Analysis with Data Science advanced level.*
https://www.kaggle.com/code/midouazerty/gdp-analysis-with-data-science-advanced-level

8 Mã nguồn

Truy cập toàn văn mã nguồn tại **GitHub Repository**